

Diseño e Implementación de un Data Warehouse y Tablero Analítico para el Monitoreo del Macroentorno Económico, Social y Educativo del Ecuador

Juan Diego Villamagua Alvarado
*Carrera de Ingeniería en Ciencias de la Computación
Universidad Técnica Particular de Loja, Loja, Ecuador*

Resumen— El presente artículo describe el diseño e implementación de una arquitectura de datos tipo medallón (Bronze-Silver-Gold) orientada a integrar fuentes públicas dispersas del Ecuador (Banco Central del Ecuador, INEC, MinEduc-AMIE, Superintendencia de Compañías) en un modelo relacional único que permita el análisis territorial e histórico del macroentorno nacional. Sobre este modelo se construyó un tablero analítico en Power BI compuesto por tres vistas: evolución del Producto Interno Bruto, concentración sectorial y provincial de la actividad económica, y relación entre bachilleres graduados y empresas activas por provincia. Se documentan los principales retos técnicos enfrentados durante la construcción del pipeline ETL y de las vistas analíticas, entre ellos problemas de granularidad geográfica entre fuentes y de concurrencia en el motor de base de datos, así como las soluciones aplicadas. Los resultados muestran una fuerte concentración económica en pocas provincias y evidencian provincias con alto potencial de talento humano relativo a su tejido empresarial, información relevante para la toma de decisiones institucionales.

Palabras clave— *arquitectura medallón, almacén de datos, inteligencia de negocios, Power BI, PostgreSQL, macroentorno económico, Ecuador.*

I. INTRODUCCIÓN

La toma de decisiones estratégicas en instituciones de educación superior requiere de información actualizada sobre el entorno económico, social y educativo en el que operan. En Ecuador, esta información se encuentra dispersa en múltiples fuentes oficiales, cada una con su propio formato, frecuencia de actualización y nivel de granularidad geográfica, lo que dificulta su explotación conjunta [1]. Este trabajo presenta el desarrollo de un sistema de información compuesto por un proceso de extracción, transformación y carga (ETL), un modelo de datos relacional bajo arquitectura medallón, y un tablero analítico interactivo, con el propósito de responder tres preguntas de negocio: la evolución económica del país en las últimas dos décadas, la concentración sectorial y provincial de la actividad económica y el empleo, y la relación territorial entre la oferta de bachilleres y el tejido empresarial activo.

II. TRABAJOS RELACIONADOS

Las arquitecturas de datos por capas (Bronze, Silver, Gold), también conocidas como arquitectura medallón, han sido adoptadas ampliamente en proyectos de ingeniería de datos como una forma de organizar progresivamente la calidad y el nivel de agregación de la información, desde su forma cruda hasta vistas de negocio listas para consumo analítico [2]. Diversos autores destacan que este enfoque facilita la trazabilidad y la reutilización de datos limpios entre distintos casos de uso [3]. Por su parte, el uso de herramientas de autoservicio de inteligencia de negocios, como Power BI, ha

simplificado la construcción de tableros interactivos sin necesidad de desarrollo de software a medida, permitiendo a analistas no especializados en programación construir visualizaciones conectadas directamente a motores de bases de datos relacionales como PostgreSQL [4].

III. JUSTIFICACIÓN DEL ENFOQUE BASADO EN PIPELINE DE DATOS

Antes de adoptar una arquitectura de pipeline con capas Bronze-Silver-Gold, se consideraron alternativas más simples, como la conexión directa de Power BI a los archivos fuente (CSV/Excel) o la construcción de hojas de cálculo intermedias actualizadas manualmente. Ambas opciones fueron descartadas por las razones que se exponen a continuación, ya que un enfoque de pipeline automatizado resulta más adecuado para un sistema que debe integrar múltiples fuentes institucionales con actualización periódica y que será mantenido más allá de la entrega puntual del proyecto.

A. Reproducibilidad y trazabilidad

Un pipeline versionado en código (extracción en Python, transformación y vistas en SQL) documenta de forma explícita cada regla de negocio aplicada a los datos, a diferencia de una hoja de cálculo donde las transformaciones suelen quedar ocultas en fórmulas dispersas o pasos manuales no documentados. Esto permite que cualquier otro miembro del equipo, o un revisor externo, pueda reconstruir exactamente cómo se llegó de un dato crudo (por ejemplo, el directorio de compañías de la Superintendencia) a un indicador final (empresas activas por provincia), condición

señalada como deseable en proyectos de ingeniería de datos reproducibles [8].

B. Separación de responsabilidades por capas

La separación entre las capas Bronze, Silver y Gold evita que errores de limpieza se propaguen de forma silenciosa hacia el tablero final. Al aislar la limpieza (Silver) del cálculo de negocio (Gold), fue posible, por ejemplo, corregir la vista `gold_bachilleres_vs_empresas` sin necesidad de tocar ni reprocesar la extracción original de los datos de MinEduc o de la Superintendencia de Compañías, reduciendo el tiempo de corrección y el riesgo de introducir nuevos errores en otras vistas que ya funcionaban correctamente.

C. Escalabilidad ante nuevas fuentes o actualizaciones periódicas

Las fuentes utilizadas (BCE, INEC, MinEduc, Supercías) se actualizan con distinta periodicidad. Un pipeline automatizado permite reejecutar únicamente las etapas de extracción y carga sin rediseñar el modelo relacional ni los tableros, mientras que un enfoque manual obligaría a repetir el proceso completo de limpieza cada vez que una fuente publique una nueva versión de sus datos, lo cual es inviable a mediano plazo para un sistema pensado para uso institucional continuo [9].

D. Consistencia entre múltiples consumidores

Al centralizar la lógica de negocio en vistas SQL de la capa Gold, se garantiza que cualquier herramienta de consumo (Power BI u otra en el futuro) obtenga exactamente la misma definición de cada indicador. Si, en cambio, cada consumidor calculara sus propias métricas mediante medidas DAX independientes sin una capa Gold subyacente, existiría el riesgo de que dos áreas de la institución reporten cifras distintas para el mismo concepto, un problema documentado como fuente común de desconfianza en sistemas de inteligencia de negocios sin gobierno de datos centralizado [4].

E. Costo de mantenimiento a largo plazo

Si bien la construcción inicial de un pipeline automatizado exige mayor esfuerzo de diseño que una conexión directa o una hoja de cálculo, el costo de mantenimiento posterior es significativamente menor: los ajustes identificados durante este proyecto, como la corrección de la clave de cruce entre bachilleres y empresas activas, se resolvieron modificando un único script SQL reutilizable, en lugar de corregir manualmente decenas de celdas o fórmulas dispersas en un archivo de hoja de cálculo cada vez que se recibe una nueva versión de los datos fuente.

IV. ARQUITECTURA DEL SISTEMA

A. Arquitectura medallón

El sistema se organiza en tres capas. La capa Bronze almacena los datos crudos extraídos de las fuentes originales (archivos CSV del Banco Central del Ecuador, del Instituto Nacional de Estadística y Censos, del sistema AMIE del Ministerio de Educación, y del directorio de la Superintendencia de

Compañías) sin ninguna transformación. La capa Silver contiene los datos limpios, tipados y estandarizados, incluyendo dimensiones compartidas como geografía, tiempo y clasificación industrial (CIU). La capa Gold contiene vistas relacionales orientadas a negocio, calculadas mediante consultas SQL sobre la capa Silver, listas para ser consumidas directamente por el tablero analítico [5].

B. Modelo de datos e integración de fuentes heterogéneas

Uno de los principales retos identificados durante el desarrollo fue la heterogeneidad en la granularidad geográfica de las fuentes de origen. La dimensión de geografía (`dim_geografia`) fue diseñada para representar tanto provincias como cantones bajo un identificador único (`id_geo`); sin embargo, las distintas fuentes cargaron su información a niveles de detalle diferentes: los registros del Ministerio de Educación se cargaron a nivel de provincia y cantón, mientras que los registros de la Superintendencia de Compañías se cargaron únicamente a nivel de provincia. Esta diferencia provocó que un cruce (JOIN) realizado por el identificador numérico de geografía no encontrara coincidencias entre ambas fuentes, a pesar de referirse a la misma entidad territorial. La solución adoptada consistió en realizar el cruce por el atributo de texto compartido entre ambas fuentes (nombre de provincia) en lugar del identificador numérico, evitando así la pérdida de información en la vista analítica resultante.

V. IMPLEMENTACIÓN

A. Extracción y limpieza de datos

La extracción de los conjuntos de datos se automatizó mediante scripts en Python utilizando la biblioteca `pandas` para el tratamiento de valores nulos e inconsistencias, particularmente en el conjunto de datos AMIE del Ministerio de Educación. Posteriormente, un pipeline de carga automatizada transfiere los datos procesados hacia una base de datos PostgreSQL, organizada en los esquemas `silver` y `gold` [6].

B. Vistas analíticas (capa Gold)

Se construyeron seis vistas Gold: `gold_pib_tendencia` y `gold_petroleo_30dias`, que resumen indicadores macroeconómicos de tendencia; `gold_empleo_tendencia`, que expone indicadores de la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU); `gold_empresas_provincia`, que agrega el número de empresas activas por provincia a partir del directorio de la Superintendencia de Compañías; `gold_bachilleres_vs_empresas`, que relaciona el número de bachilleres de tercer año con el número de empresas activas por provincia; y `gold_oportunidad_utpl_provincia`, una vista derivada que clasifica cada provincia en niveles de oportunidad institucional (alta, media o baja) en función del cociente entre bachilleres y empresas activas.

C. Concurrencia y estabilidad del motor de base de datos

Durante la fase de validación se identificó un comportamiento anómalo del motor PostgreSQL en el que determinadas

consultas de agregación quedaban indefinidamente en estado de espera, sin completar su ejecución ni devolver un error explícito. El análisis de los registros del servidor (logs) reveló que la causa era un fallo al mapear segmentos de memoria compartida dinámica requeridos por los procesos de ejecución paralela de consultas (parallel workers), un comportamiento reportado en entornos Windows con determinadas configuraciones de memoria [7]. La solución aplicada consistió en deshabilitar el paralelismo de consultas a nivel de sesión mediante el parámetro `max_parallel_workers_per_gather`, lo cual restauró tiempos de respuesta normales sin afectar la corrección de los resultados.

D. Tablero analítico

El tablero se implementó en Power BI Desktop, conectado directamente a las vistas del esquema gold mediante un conector nativo de PostgreSQL. Se diseñaron tres páginas: (1) evolución económica, con una serie temporal del PIB real, variación porcentual anual clasificada por ciclo económico y un indicador clave de desempeño (KPI) de PIB per cápita; (2) concentración sectorial y provincial, con la distribución del valor agregado bruto (VAB) por provincia y del empleo por rama de actividad CIU; y (3) bachilleres frente a empresas, con un gráfico comparativo por provincia y una tabla de las provincias con mayor razón bachilleres/empresas, resaltadas mediante formato condicional según su nivel de oportunidad.

VI. RESULTADOS

El análisis de la vista `gold_pib_tendencia` evidenció una tendencia general de crecimiento del PIB real ecuatoriano en el periodo analizado, con una contracción notable coincidente con la crisis sanitaria global de 2020. La vista `gold_productividad_vab_empleo` mostró una fuerte concentración del valor agregado bruto en pocas provincias, lideradas por Guayas, mientras que el empleo se concentró principalmente en actividades de comercio y agricultura, sectores de menor productividad relativa frente a los sectores financiero e industrial. Finalmente, el cruce entre bachilleres y empresas activas (`gold_bachilleres_vs_empresas`) permitió identificar provincias con una razón bachilleres/empresas considerablemente más alta que el promedio nacional, lo que sugiere la existencia de talento humano potencial no absorbido por el tejido empresarial local, información de relevancia estratégica para la planificación de oferta académica institucional.

VII. CONCLUSIONES

El desarrollo de este proyecto permitió comprobar que la arquitectura medallón facilita la integración de fuentes públicas heterogéneas, siempre que se preste especial atención a la consistencia de las claves de cruce entre fuentes, en particular cuando estas presentan distintos niveles de granularidad geográfica. Asimismo, se evidenció la importancia de monitorear el comportamiento del motor de base de datos ante configuraciones específicas del sistema operativo anfitrión. Como trabajo futuro se plantea la incorporación de un mapa coroplético con la división político-

administrativa oficial del Ecuador, la extensión del análisis de oportunidad a un componente ponderado por volumen absoluto de bachilleres, y la automatización completa del pipeline mediante un orquestador de tareas.

REFERENCIAS

- [1] T. Dasu and T. Johnson, *Exploratory Data Mining and Data Cleaning*, 2nd ed. Hoboken, NJ, USA: Wiley, 2014.
- [2] D. Sculley et al., "Hidden technical debt in machine learning systems," in *Proc. 28th Int. Conf. Neural Inf. Process. Syst.*, Montreal, Canada, 2015, pp. 2503–2511.
- [3] M. Armbrust et al., "Delta lake: high-performance ACID table storage over cloud object stores," *Proc. VLDB Endowment*, vol. 13, no. 12, pp. 3411–3424, 2020.
- [4] A. Ferrari and M. Russo, *Analyzing Data with Power BI and Power Pivot for Excel*. Redmond, WA, USA: Microsoft Press, 2017.
- [5] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN, USA: Wiley, 2013. (ed. revisada 2016)
- [6] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2017.
- [7] PostgreSQL Global Development Group, "PostgreSQL 16 documentation: Parallel query," PostgreSQL.org, 2023. [Online]. Available: <https://www.postgresql.org/docs/current/parallel-query.html>
- [8] J. M. Hellerstein, V. Sreekanti, J. E. Gonzalez et al., "Ground: A data context service," in *Proc. 8th Biennial Conf. Innovative Data Systems Research (CIDR)*, Chaminade, CA, USA, 2017, pp. 1–12.
- [9] P. Russom, "Data lifecycle management for data warehousing," TDWI Best Practices Report, TDWI Research, Renton, WA, USA, 2019.
- [10] Banco Central del Ecuador, "Cuentas nacionales trimestrales del Ecuador," BCE, Quito, Ecuador, 2023.
- [11] Instituto Nacional de Estadística y Censos, "Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU)," INEC, Quito, Ecuador, 2023.
- [12] Ministerio de Educación del Ecuador, "Sistema de Registro de Datos Educativos (AMIE)," MinEduc, Quito, Ecuador, 2023.
- [13] Superintendencia de Compañías, Valores y Seguros, "Directorio de compañías activas," SUPERCIAS, Quito, Ecuador, 2023.
- [14] C. Bishop, *Pattern Recognition and Machine Learning Applied to Regional Economic Indicators*, 2nd ed. New York, NY, USA: Springer, 2016.